

FAQ — FlotaLogix

Azucena Orduña · Daniel Miranda | ITAM — Arquitectura de Productos de Datos

Contents

FlotaLogix	3
1. Tecnologías utilizadas	3
1.1 Infraestructura en la nube (AWS)	3
2. Uso de la aplicación	3
2.1 Pipeline de datos	4
2.2 Aplicación web	4
3. Adquisición y uso de datos	4
3.1 Fuentes de datos	4
3.2 Flujo de datos (arquitectura medallion)	5
3.3 Variables utilizadas por el modelo	5
3.4 Base de datos en producción	6
4. ¿Qué tipo de analítica o inteligencia se aplica?	6
4.1 Machine Learning supervisado — Clasificación binaria	6
4.2 Modelado con variable latente (generación de datos sintéticos)	7
4.3 Agente conversacional con LLM (Claude Sonnet via Amazon Bedrock)	10
4.4 Analítica descriptiva	10
Frecuencia de servicios para identificar qué tipos de mantenimiento son más recurrentes y costosos.	10
5. Inputs y outputs del producto	10
5.1 Inputs	10
5.2 Outputs	11

6. ¿Cómo consume el usuario final los outputs?	11
6.1 El Gerente del Taller	11
6.2 El Mecánico	12
6.3 Historial y los Reportes	13
7. Costo anual	13
7.1 Desglose de infraestructura AWS	14
7.3 Costo por taller	14
8. Limitaciones y siguientes pasos	14
{r setup, include=FALSE} knitr::opts_chunk\$set(echo = FALSE, message = FALSE, warning = FALSE)	

FlotaLogix

Es una herramienta diseñada para talleres mecánicos especializados en el mantenimiento de flotas de transporte de carga pesada. La herramienta digitaliza el registro de reparaciones y aplica modelos de Machine Learning para anticipar qué vehículos de la flota atendida requieren servicio antes de que fallen transformando la operación del taller de reactiva a predictiva.

El sistema combina un pipeline de datos en la nube, un modelo de clasificación entrenado con variables operativas reales, un agente conversacional para guiar al mecánico, y un dashboard interactivo para el gerente del taller.

Usuario

El cliente del producto es el **taller mecánico** que da servicio a grandes flotas logísticas. El usuario directo es el **mecánico o ayudante** que registra reparaciones en el día a día, y el **gerente del taller** que necesita visibilidad sobre el estado de la flota que atiende.

1. Tecnologías utilizadas

1.1 Infraestructura en la nube (AWS)

La aplicación corre sobre Amazon Web Services.

Los componentes de infraestructura son:

Servicio	Rol en el sistema
Amazon S3	Data lake con arquitectura medallón (Bronze → Silver → Gold)
Amazon RDS — PostgreSQL 17	Base de datos transaccional con réplica de lectura
Amazon SageMaker Studio	Entorno de ejecución de los notebooks del pipeline
Amazon ECS Fargate	Contenedor donde corre la aplicación Streamlit en producción
Amazon Bedrock	Modelo de lenguaje que alimenta al agente conversacional
AWS Secrets Manager	Almacenamiento seguro de credenciales de base de datos
AWS CloudFormation	Infraestructura como código para el stack <code>autoshop-rds</code> y ECS

La infraestructura se aprovisiona de forma reproducible mediante dos templates de CloudFormation: `rds-autoshop.yaml` para la base de datos y `ecs-fargate-app.yaml` para la aplicación.

2. Uso de la aplicación

El sistema tiene dos capas de uso: el **pipeline de datos** que corre en la nube de forma periódica, y la **aplicación web** que usan el gerente y los mecánicos en el día a día.

2.1 Pipeline de datos

El pipeline está compuesto por cinco notebooks que se ejecutan en secuencia:

00_data_generation : Generación de datos sintéticos Genera 5,000 vehículos con características realistas distribuidos en 6 talleres de la ZMVM. Utiliza una variable latente `health_score ~ Beta(2, 3)` para simular correlaciones no lineales entre condición operativa y probabilidad de falla. Este notebook se ejecuta una sola vez para inicializar el sistema con datos de arranque.

01_etl : ETL (Extracción, Transformación, Carga) Lee los archivos CSV generados en el notebook anterior, valida rangos operativos (por ejemplo, `usage_hours` [0, 50,000] y `tire_pressure` [10, 100]), y escribe la capa **Silver** en formato Parquet en S3. Esta capa es la base limpia sobre la que opera el modelo.

02_eda_features : EDA y Feature Engineering Construye dos variables derivadas clave que no existen en los datos originales:

- `days_since_maintenance`: días transcurridos desde el último servicio registrado.
- `load_ratio`: cociente entre la carga actual y la capacidad máxima del vehículo (`Actual_Load / Load_Capacity`).

El resultado se escribe en la capa **Gold**, lista para modelado.

03_model : Entrenamiento del modelo y cálculo de scores Entrena el pipeline XGBoost con los datos Gold, evalúa el modelo contra el umbral de accuracy 0.75, y genera un score de riesgo (0–100) para cada uno de los 5,000 vehículos. El artefacto `model_xgb.pkl` y los scores se suben a S3.

04_rds : Carga a RDS Inserta el catálogo de vehículos, los scores de riesgo y el catálogo de servicios en la base de datos PostgreSQL.

2.2 Aplicación web

<http://auto-repair-shop-alb-1836861376.us-east-1.elb.amazonaws.com/>

La aplicación Streamlit tiene tres pestañas, cada una diseñada para un perfil de usuario distinto:

Pestaña Gerente Vista de mando del taller. Muestra KPIs en tiempo real (flota total, vehículos en zona roja, costo acumulado de mantenimiento), un mapa interactivo con los CEDIS agrupados por nivel de riesgo, la lista de vehículos en zona roja ordenada por score, y dos gráficas: costo mensual acumulado y servicios más frecuentes. El gerente puede filtrar por centro de distribución y nivel de gravedad.

Pestaña Mecánico Interfaz de registro guiado. Flujo conversacional de 7 pasos lleva al mecánico a capturar: placa del vehículo, tipo de servicio, descripción del trabajo, refacciones utilizadas, horas trabajadas, costo total y nombre del responsable. Cada dato ingresado aparece simultáneamente en un panel de resumen a la derecha. Al confirmar, el registro se guarda en `maintenance_records` en RDS y el score del vehículo se actualiza automáticamente.

Pestaña Historial Permite consultar y filtrar el historial completo de servicios por placa, tipo de servicio y rango de fechas. Incluye KPIs de la selección (número de servicios, costo total, promedio por servicio, vehículos únicos) y un botón de descarga del reporte en CSV.

3. Adquisición y uso de datos

3.1 Fuentes de datos

El sistema parte de dos datasets públicos de Kaggle, complementados con datos sintéticos generados internamente:

logistics-vehicle-maintenance-history <https://www.kaggle.com/datasets/datasetengineer/logistics-vehicle-maintenance-history-dataset>

92,000 registros de vehículos con 27 variables entre ellas: horas de uso, presión de llantas, consumo de combustible, condición de frenos, historial de fallas, anomalías detectadas, condiciones de ruta y clima, entre otras. Variable objetivo: `Maintenance_Required` (binaria).

vehicle-service-and-repair <https://www.kaggle.com/datasets/neerugattvikram/vehicle-service-and-repair-dataset-for-analysis>


Placas de vehículos, asignación a taller, variable `health_score` ~ $\text{Beta}(2,3)$ como proxy de condición real.

Datos sintéticos

Generación propia. Placas de vehículos, asignación a taller, variable `health_score` ~ $\text{Beta}(2,3)$ como proxy de condición real. |

3.2 Flujo de datos (arquitectura medallion)

Los datos atraviesan cuatro capas de procesamiento, cada una almacenada en S3:



3.3 Variables utilizadas por el modelo

El modelo de clasificación usa 16 variables seleccionadas explícitamente para evitar data leakage:

Variables numéricas (10): `Usage_Hours`, `Tire_Pressure`, `Fuel_Consumption`, `Battery_Status`, `Vibration_Levels`, `Failure_History`, `Anomalies_Detected`, `Delivery_Times`, `days_since_maintenance`, `load_ratio`.

Variables categóricas (6): `Vehicle_Type`, `Route_Info`, `Oil_Quality`, `Brake_Condition`, `Weather_Conditions`, `Road_Conditions`.

Variables excluidas por data leakage: `Predictive_Score`, `Maintenance_Cost`, `Downtime_Maintenance`, `Impact_on_Efficiency`. Estas variables se calculan después del evento de mantenimiento, por lo que su inclusión inflaría el desempeño del modelo.

3.4 Base de datos en producción

La base de datos PostgreSQL (RDS) tiene cinco tablas:

Tabla	Contenido
<code>vehicles</code>	Catálogo de vehículos con placa, modelo, año, tipo, ruta y taller asignado
<code>risk_scores</code>	Score de riesgo actual por vehículo, nivel (Alto/Medio/Bajo) y timestamp del cálculo
<code>service_catalog</code>	Catálogo estandarizado de problemas y soluciones aplicadas
<code>maintenance_records</code>	Registro de cada servicio capturado: fecha, problema, solución, refacciones, costo y mecánico
<code>model_run_log</code>	Metadata de cada ejecución del pipeline: versión del modelo, accuracy, número de vehículos procesados

Las escrituras van al host primario; las lecturas del dashboard y del agente van a la **réplica de lectura**, separando la carga operativa.


4. ¿Qué tipo de analítica o inteligencia se aplica?

El producto combina tres tipos de inteligencia:

4.1 Machine Learning supervisado — Clasificación binaria

Es un **pipeline scikit-learn + XGBoost** que predice si un vehículo requiere mantenimiento o no (`Maintenance_Required`: 1 / 0).

Arquitectura del pipeline:





Parámetros de entrenamiento:

- Semilla de aleatoriedad: `random_seed = 123`
- Partición: 80% entrenamiento / 20% prueba
- Umbral de aprobación: `accuracy > 0.75` en el conjunto de prueba
- Resultado obtenido: **accuracy = 0.775**

El artefacto entrenado (`model_xgb.pkl`) se sube a S3 y el dashboard puede descargarlo para calcular un re-score on demand.

4.2 Modelado con variable latente (generación de datos sintéticos)


El dataset original de Kaggle incluye variables como `Anomalies_Detected` y `Failure_History` que, al inspeccionarse, no son variables operacionales independientes sino que fueron construidas en función de `Maintenance_Required`.



Vemos que son las únicas variables que tienen correlación con la variable objetivo y que la mayoría de sus covariables

No se descartan como las variables que ocasionan data leakage ya que sí las tendríamos antes del target. Al correr el modelo con estos valores se tenía un accuracy prácticamente del 100%.

Para lograr ejemplificar cómo funcionaría el modelo con datos más apegados a la realidad, se decidió generar un dataset sintético donde todas las variables operacionales emergen de un factor latente no observable, el **health_score** que representa el estado de salud real del vehículo. Este score nunca se expone al modelo, solo guía la generación. Así, las correlaciones entre los features y el target son realistas y causalmente, pero ningún feature es una función directa de **Maintenance_Required**.



Para inicializar el sistema con datos estadísticamente válidos se utiliza un **modelo de variable latente**:

```
health_score ~ Beta(=2, =3)
```

La distribución Beta(2,3) está sesgada hacia valores bajos (mayor riesgo), lo que produce una distribución realista de condición vehicular donde la mayoría de los vehículos tienen algún grado de deterioro. Este score latente controla la probabilidad de que **Maintenance_Required = 1**, generando correlaciones no lineales naturales entre las variables operativas y la variable objetivo.

4.3 Agente conversacional con LLM (Claude Sonnet via Amazon Bedrock)

El sistema incluye un **agente inteligente** para el mecánico, construido con el framework Strands Agents. El agente usa el modelo `claude-sonnet-4-6` de Anthropic disponible en Amazon Bedrock, y tiene acceso a cuatro herramientas:

Herramienta	Función
<code>consultar_estado_vehiculo(placa)</code>	Consulta el score de riesgo, nivel y modelo del vehículo desde la réplica RDS
<code>buscar_historial_vehiculo(placa, n)</code>	Devuelve los últimos N servicios registrados para una unidad
<code>sugerir_refacciones(tipo_servicio)</code>	Sugiere las refacciones más comunes según el tipo de mantenimiento
<code>registrar_servicio(...)</code>	Escribe un nuevo registro en <code>maintenance_records</code> en RDS primario

El agente mantiene **memoria de conversación** dentro de la sesión, lo que le permite guiar al mecánico paso a paso sin perder el contexto entre preguntas. El sistema prompt instruye al agente a responder en español, de forma concisa y práctica, adaptado al ritmo de trabajo de un taller.

4.4 Analítica descriptiva

La pestaña Gerente del dashboard incluye:

- **Análisis de costo acumulado por mes** con gráfica de barras mensuales y línea de acumulado.
-

Frecuencia de servicios para identificar qué tipos de mantenimiento son más recurrentes y costosos.

5. Inputs y outputs del producto

5.1 Inputs

Input	Formato	Origen	Frecuencia
Dataset logístico de vehículos	CSV	Kaggle	Una vez / re-entrenamiento
Dataset de servicios y reparaciones	CSV	Kaggle	Una vez / actualización
Datos sintéticos de flota	Generados en NB00	Código interno	Inicialización
Archivo de configuración	<code>config.yaml</code>	Repositorio	Al cambiar parámetros
Credenciales de base de datos	JSON	AWS Secrets Manager	En tiempo de ejecución
Registro de servicio (mecánico)	Formulario web	Pestaña Mecánico	Por cada servicio realizado
Consulta del agente (texto libre)	Chat	Pestaña del agente	Por cada interacción

5.2 Outputs

Output	Formato	Destino	Descripción
Datos Bronze	CSV (sin modificar)	S3 bronze/	Copia fiel de las fuentes originales
Datos Silver	Parquet	S3 silver/	Datos limpios y validados
Datos Gold	Parquet	S3 gold/	Features finales listos para modelado
Scores de riesgo	Parquet	S3 gold/risk_scores/	Score 0–100 y etiqueta binaria por vehículo
Modelo entrenado	.pkl (joblib)	S3 models/model_xgb.pkl	Pipeline serializado para re-inferencia
Metadata del modelo	JSON	S3 models/model_metadata.json	Versión, accuracy, fecha, features usados
Tabla vehicles	PostgreSQL	RDS	Catálogo maestro de unidades
Tabla risk_scores	PostgreSQL	RDS	Scores consultables por la app
Tabla maintenance_records	PostgreSQL	RDS	Registro de cada servicio capturado
Tabla model_run_log	PostgreSQL	RDS	Trazabilidad de ejecuciones del pipeline
Dashboard interactivo	Aplicación web	Streamlit / ECS Fargate	Visualización en tiempo real
Reporte de historial	CSV descargable	Navegador del usuario	Exportación de servicios filtrados
Respuesta del agente	Texto	Chat en la app	Guía al mecánico


6. ¿Cómo consume el usuario final los outputs?

6.1 El Gerente del Taller

El gerente accede al sistema a través de la **Pestaña Gerente** en la aplicación web.

Al abrir la aplicación, se muestra: total de vehículos en la flota atendida, cuántos están en zona roja (riesgo Alto), cuántos están disponibles sin mantenimiento pendiente, cuántos requieren servicio y el costo acumulado total de mantenimiento.

También cuenta con un mapa interactivo que muestra los talleres con un marcador de semáforo en función del riesgo promedio de sus unidades. Al pasar el cursor sobre un marcador, aparece el nombre del CEDIS, la cantidad de vehículos asignados y cuántos están en zona roja. Puede filtrar por taller y nivel de riesgo.



También aparece la **lista de vehículos en zona roja**, ordenada por score de mayor a menor, con placa, modelo, taller y modelo de la unidad.

En la parte inferior cuenta con información sobre gastos reparación y trabajos más comunes.

En general se brinda información para poder optimizar su operación, desde necesidades de inventario (con la gráfica de reparaciones más comunes) hasta concentración de la fuerza de trabajo al ver dónde se requiere mayor número de mecánicos para las unidades de alto riesgo.

6.2 El Mecánico

El mecánico accede a la **Pestaña Mecánico**. El sistema lo guía con un flujo de 7 preguntas, una a la vez, en formato de chat:

1. Selecciona la placa del vehículo que ingresa al taller.
2. Selecciona el tipo de servicio que presenta la unidad.
3. Escribe una descripción del trabajo realizado.
4. Selecciona las refacciones utilizadas del catálogo estandarizado (selección múltiple).
5. Indica las horas de trabajo.
6. Captura el costo total del servicio en MXN.
7. Selecciona el nombre del mecánico responsable.

Mientras responde cada pregunta, un panel a la derecha muestra en tiempo real el resumen del registro que se está construyendo. Al finalizar, el mecánico confirma el registro.

FlotaLogix
Gestión integral de Flota - Panel de Control Operativo

23 May 2018
Turno 07:00 - 14:00 h

Inicio Mecánica Historial

Registro de servicio

Responde cada pregunta para registrar el servicio. El resumen se actualiza en tiempo real.

¿Cuál es la placa del vehículo que ingresa a taller?

AAA-693

¿Qué problema presenta la unidad?

AC not cooling

Describe el trabajo realizado o el problema detectado.

damage to the left structure

¿Qué refacciones se utilizaron? (puedes seleccionar varias)

Radiador, Termostato

¿Cuántas horas de trabajo fueron necesarias?

2.5 hrs

¿Cuál es el costo total del servicio? (MÓN)

\$2,000 MÓN

¿Quién realizó el servicio?

Antonio Lima

Paso 7 de 7 - Confirmación

Descripción normalizada (detectado: ex):
Damage to the left AC structure
Corrected spelling of 'structure' to 'structure' and clarified that damage is related to the AC system.

¿Perfecto! Todos los datos están bien. ¿Confirmas el registro de este servicio?

Confirmar registro Editar respuestas

Resumen del registro

AAA-693
Toyota - Sep 2018
(Carga foto: 10 MB)

Vehículo AAA-693

Tipo de servicio AC not cooling

Descripción damage to the left structure

Refacciones Radiador, Termostato

Horas trabajadas 2.5 hrs

Costo total \$2,000 MÓN

Mecánico Antonio Lima

6.3 Historial y los Reportes

Cualquier usuario del taller puede acceder a la **Pestaña Historial** para consultar el registro completo de servicios. Los filtros disponibles son: placa, tipo de servicio, fecha de inicio y fecha de fin. La tabla resultante muestra fecha, servicio, solución aplicada, costo y notas del mecánico. Un botón de descarga genera un CSV con los registros filtrados, listo para compartir con el cliente flota o para análisis interno.

FlotaLogix
Gestión integral de Flota - Panel de Control Operativo

23 May 2018
Turno 07:00 - 14:00 h

Inicio Mecánica **Historial**

Historial de servicios

Placa: Todas las placas | Tipo de servicio: Todos los servicios | Desde: 2026/05/22 | Hasta: 2026/05/23

Servicios encontrados: **9** | Costo total: **\$8,377** | Promedio por servicio: **\$931** | Vehículos únicos: **6**

Placa	Marca	Tipo	Fecha	Servicio	Solución aplicada	Costo MÓN	Notas mecánico
AAA-693	Toyota Hilux	Suv	23/05/2026	AC not cooling	Radiador, Termostato	\$2000	PROBLEM: AC not cooling WORK_DONE: Damage to the left AC structure PARTS_USED: Radiador, Termostato LABOR: 2.5 hrs
ALU-362	Ford F-450	Bus	23/05/2026	AC not cooling	Acople de motor 159H-40	\$123	PROBLEM: AC not cooling WORK_DONE: Expired refrigerant PARTS_USED: Acople de motor 159H-40 LABOR: 2.0 hrs
AAA-693	Toyota Hilux	Suv	23/05/2026	AC not cooling	Batería 27D	\$1000	PROBLEM: AC not cooling WORK_DONE: AC not cooling - plantillas PARTS_USED: Bateria 27D LABOR: 2.0 hrs
DWV-346	Toyota Hilux	Truck	23/05/2026	Misaligned tires	Acople de motor 159H-40	\$477	alineacion y balances Refacciones: Acople de motor 159H-40 2.0 hrs Marcos Salinas
DWV-346	Toyota Hilux	Truck	23/05/2026	Misaligned tires	Acople de motor 159H-40	\$477	alineacion y balances Refacciones: Acople de motor 159H-40 2.0 hrs Marcos Salinas
BJW-329	Iscru Nigr	Suv	22/05/2026	Brake noise	Pastillas de freno delanteras	\$290	brakes manufacturing issue Refacciones: Pastillas de freno delanteras 2.0 hrs José Pérez
AKN-744	Tesla Semi	Suv	22/05/2026	Tire damage	Amortiguador delantero	\$900	Patch tire Refacciones: Amortiguador delantero 2.0 hrs José Pérez
AKN-744	Tesla Semi	Suv	22/05/2026	AC not cooling	Termostato	\$1000	The air conditioning system is not working due to a lack of antihese Refacciones: Termostato 3.0 hrs Marcos Sal
AAH-605	Tesla Semi	Truck	22/05/2026	Cloudy headlights	Batería 27D, Amortiguador delantero, Banda serpentina	\$1000	electric fuse damaged Refacciones: Bateria 27D, Amortiguador delantero, Banda serpentina 2.0 hrs Marcos Sal

Descargar CSV

7. Costo anual

El costo anual está calculado para un escenario con **6 talleres activos**, **2 usuarios recurrentes por taller** (**12 usuarios totales**), atendiendo una flota total de 5,000 vehículos.

7.1 Desglose de infraestructura AWS

Componente	Servicio	Especificación	Costo mensual	Costo anual
Base de datos primaria	RDS PostgreSQL 17	db.t3.micro, 20 GB gp3, Single-AZ	\$17.00	~\$204
Réplica de lectura	RDS Read Replica	db.t3.micro, misma región	\$17.00	~\$204
Data lake	S3 Standard	~8 GB (Bronze + Silver + Gold + modelos, 6 talleres)	\$0.30	~\$3.60
Credenciales	Secrets Manager	1 secret compartido activo	\$0.40	\$4.80
Pipeline de datos	SageMaker Studio	ml.t3.medium, ~20 h/mes (NB00–NB04)	\$1.20	~\$14.40
Aplicación web	ECS Fargate	0.5 vCPU / 1 GB RAM, 730 h/mes (12 usuarios concurrentes)	\$18.00	~\$216.00
Modelo de lenguaje	Amazon Bedrock (Claude Sonnet)	~2,500 consultas/mes (6 talleres × 2 usuarios)	\$10.00	~\$120.00
Total estimado			\$64	\$768

Costos aproximados en dólares.

7.3 Costo por taller

Concepto	Costo mensual	Costo anual
Infraestructura compartida (RDS + S3 + SageMaker + Secrets)	\$19	\$228
Aplicación web (ECS Fargate)	\$18	\$216
Bedrock — porción por taller (2,500 consultas / 6)	\$1.67	\$20
Costo por taller	\$6.30	\$77
Costo total (6 talleres)	\$64	\$770

El costo por taller resulta especialmente bajo porque la infraestructura de datos (RDS, S3, SageMaker) es compartida: escalar de 1 a 6 talleres no multiplica los costos fijos por 6, sino que los distribuye.

8. Limitaciones y siguientes pasos

La aplicación requiere conexión a internet permanente La aplicación web y el agente requieren conexión para consultar RDS y Bedrock. El pipeline de datos requiere acceso a S3 y SageMaker durante su ejecución. No hay componentes que operen offline.

Como siguiente paso para la evolución del producto, la interfaz de registro para el mecánico migraría de la aplicación Streamlit a un **chatbot dentro de WhatsApp**.

Esta migración reduciría aún más la fricción de abrir una aplicación web y permitiría al mecánico registrar servicios, consultar el estado de un vehículo y recibir sugerencias de refacciones directamente desde su celular, sin instalar nada adicional. El agente conversacional ya está construido con esta lógica de interacción en mente.